

Projet 2025 - Analyse des déterminants génétiques de pathways candidats sur le risque de cancer

PE Sugier

Introduction

Un consortium national s'intéresse aux déterminants génétiques sur le risque de cancer. Il souhaiterait en particulier explorer l'effet des variants génétiques impliqués dans de 10 voies biologiques (pathways) déjà identifiées comme jouant un rôle dans le cancer. Des jeux de données issus de deux centres hospitaliers en France ont pu être rassemblés. Un premier contrôle qualité a déjà été effectué sur les données.

Les données ont également reçu un pré-traitement :

- des SNPs manquants pour l'une des études ont été imputés sous forme de dosage génétique (espérance du compte des allèles)
- les données génétiques ont été annotées (correspondances SNPs-gènes et gènes-pathways)
- une ACP a été effectuée séparément dans chaque centre pour générer les composantes principales sur lesquelles ajuster afin d'éviter le problème de stratification de population.

Consignes

Il vous ai demandé dans un premier temps de réaliser des analyses préliminaires de type GWAS sur ces données (considérant 3707 SNPs annotés au pathways candidats) afin de générer des données résumées. Vous pourrez vous référer au cours, et expliciter votre démarche pour leur génération.

A la suite de ça, vous pourrez

- Présenter vos résultats d'analyse au niveau des SNPs dans un graphique (par exemple de type manhattan-plot) et commenter sur la significativité des tests statistiques effectués
- Proposer une analyse au niveau des gènes en reproduisant la méthode vue en cours (commenter/les différentes statistiques possibles) et exploitant la covariance de vos données. Vous pourrez faire l'approximation que les covariances sont les mêmes dans les deux échantillons.
- Tester l'enrichissement en gènes détectés lors de l'étape précédente pour chacun des 10 pathways étudiés. Vous pourrez éventuellement comparer plusieurs méthodes.

Vous aurez 10 minutes pour présenter vos travaux de groupe (2 personnes) le 5 mai (pas de rapport à envoyer). Un dépassement du temps pourra être sanctionné. Lors de cette présentation, vous devrez expliciter votre démarche méthodologique de façon concise, et illustrer vos résultats d'analyse pour chaque méthode utilisée. Enfin, vous pourrez conclure sur les principaux résultats, et éventuellement les limites de vos analyses.

Votre présentation pourra être suivie d'une courte séance de questions.

Prise en main des données

Chargez les données :

Vous pouvez utiliser la fonction `ls()` pour regarder de plus près quels objets vous avez à manipuler.

```
ls(data)
```

```
## [1] "annot" "fun" "sample1" "sample2"
```

Chaque échantillon contient trois objets, Y correspondant au phénotype, X aux données génétiques, et Cov aux covariables. Les mêmes identifiants des lignes de ces trois objets pour la même étude correspondent aux mêmes individus.

```
ls(data$sample1)
```

```
## [1] "COVb" "Xb" "Yb"
```

```
ls(data$sample2)
```

```
## [1] "COVt" "Xt" "Yt"
```

Par exemple, pour l'étude 1 :

```
dim(data$sample1$Xb)
```

```
## [1] 2297 3707
```

```
length(data$sample1$Yb)
```

```
## [1] 2297
```

```
dim(data$sample1$COVb)
```

```
## [1] 2297 5
```

En particulier, pour les données de covariables...

```
head(data$sample1$COVb)
```

```
##   numind dep age      PC1      PC2
## 1 210003  1  69 1.8649947 0.2086676
## 2 210016  1  41 0.8265842 -1.1866587
## 3 210053  1  65 2.0808710 1.9628764
## 4 210059  1  34 2.9992956 1.2464029
## 5 210070  1  63 3.0526491 2.9132851
## 6 210073  1  54 3.3979197 1.7182258
```

Les informations d'annotation disponibles seront nécessaire pour les méthodes basées sur les gènes, et pathways. Vous pouvez matcher les identifiants des SNPs, en ligne, avec les colonnes des données génétiques.

```
head(data$annot)
```

```
##          snp chr      pos minor major gene      pathway dup_snp_gene
## 1  rs7531583  1 1706160      A      G NADK F_tobacco_hsa00760      <NA>
## 2  rs12044597  1 1708801      A      G NADK F_tobacco_hsa00760      <NA>
## 3   rs697679  1  7840926      C      G PER3      F_circadian      <NA>
## 4   rs697680  1  7841549      A      C PER3      F_circadian      <NA>
## 5   rs228729  1  7845695      A      G PER3      F_circadian      <NA>
## 6   rs875994  1  7852919      G      A PER3      F_circadian      <NA>
```

```
dim(data$annot)
```

```
## [1] 3707      8
```

Nota Bene

Pour ce projet, ne pas prendre en compte :

- les fonctions présentes dans “data\$fun”, créée et utilisées lors du prétraitement des données
- les covariables “dep” et “numind” pour l’étude 1.
- les covariables “IDU” et “STUDY” pour l’étude 2.
- la variable “dup_snp_gene” de la table “data\$annot”