




ANALYSE GÉNOMIQUE ET RECHERCHE DE SIGNAUX ASSOCIÉS AU CANCER

Projet réalisé dans le cadre du cours Statistiques pour la
génétique et la génomique

ANALYSE GÉNOMIQUE MULTI-NIVEAUX D'UNE COHORTE DE 3707 SNPS

Objectifs du projet


- Identifier des SNPs associés au cancer via une analyse **GWAS**
- Réunir les résultats SNPs pour faire une analyse par gène, méthode **VEGAS**
- Tester l'enrichissement fonctionnel à travers l'analyse des **pathways** biologiques



NOS DONNÉES

Structure des **données** :

- Nombre total d'individus :
 - Sample 1 : 2297 individus
 - Sample 2 : 2303 individus } 3707 SNPs
- Chaque SNP est **annoté** :
 - Au **chromosome** sur lequel il se situe
 - A sa **position** dans le gène
 - Au **gène** auquel il appartient
 - Au nom du/des **pathway(s)** dans lequel il est impliqué



ANALYSE SNP PAR SNP : MÉTHODE GWAS

Objectif :

- Identifier les variants génétiques (SNPs) associés au phénotype binaire (cancer/non cancer)

Méthodologie :

- On teste chaque SNP **individuellement** pour son association avec le cancer
- Test d'association : régression logistique pour **chaque** SNP car phénotype binaire
- Différentes covariables prises en compte pour sample 1 et sample 2 (3 covariables contre 12 covariables)
- On garde les **bêta** (effet estimé du SNP sur le phénotype) , le **standard error** (l'erreur standard de bêta) et la **p_valeur**
- Visualisation de nos GWAS

Rappel :

On teste H_0 : "Le SNPs n'est pas associé au cancer " contre H_1 : "Le SNPs est associé au cancer"


Si p_valeur est plus petit que le seuil alors on rejette H_0 $\longrightarrow$ Association entre SNP et cancer

Si p_valeur est plus grand que le seuil alors on « accepte » H_0 $\longrightarrow$ Pas d'association entre SNP et cancer

ANALYSE SNP PAR SNP : MÉTHODE GWAS


On applique donc la **régression logistique** pour nos 2 samples

Sample 1



	snp <chr>	beta <dbl>	se <dbl>	pvalue <dbl>
1	rs7531583	-0.15433958	0.07146090	0.03078997
2	rs12044597	0.02767578	0.05867416	0.63715087
3	rs697679	-0.01792820	0.06946646	0.79634187
4	rs697680	0.01817275	0.08325230	0.82720685
5	rs228729	0.04536626	0.06117898	0.45837000
6	rs875994	0.04630164	0.07428128	0.53306868

Sample 2





	snp2 <chr>	beta2 <dbl>	se2 <dbl>	pvalue2 <dbl>
1	rs7531583	-0.12903026	0.07069117	0.06796074
2	rs12044597	-0.01080159	0.05916742	0.85514351
3	rs697679	0.04093252	0.06835812	0.54930940
4	rs697680	0.02405704	0.08256809	0.77077599
5	rs228729	-0.02072159	0.06126007	0.73517028
6	rs875994	0.09141451	0.07987956	0.25245601

Beta ↘ = risque ↘

Beta ↗ = risque ↗

Seuil de significativité (Bonferroni)

Visualisation de nos GWAS



Chaque point représente les SNPs situé sur un chromosome donné.
Plus un point est haut, plus le SNP est statistiquement associé au cancer.
➡ Aucun SNP n'est significativement associé au cancer.
Certains sont "proches" de l'être, on peut approfondir nos recherches.

Les points sont les quantiles observés.
Ils sont pour la plupart alignés à la droite rouge (si sous H_0).
➡ SNP pas significativement associé au cancer.
On observe quand même des points déviants de la droite, ce qui indique quelques associations SNP/phénotype.


MÉTA-ANALYSE GWAS MODÈLE VARIANCE-INVERSE

Objectif :

- Combiner les résultats des deux analyses GWAS (sample 1 et sample 2)
- Augmenter la puissance statistique
- Obtenir une estimation plus précise de l'effet de chaque SNP sur le phénotype


Méthodologie :

- Combinaison des estimateurs bêta
 - $\beta_{combi} = \frac{w_1 * \beta_1 + w_2 * \beta_2}{w_1 + w_2}$ avec les poids $w_1 = \frac{1}{se_1^2}$ et $w_2 = \frac{1}{se_2^2}$
- L'erreur standard combinée
 - $se_{combi} = \sqrt{\frac{1}{w_1 + w_2}}$
- La statistique de test
 - $z = \frac{\beta_{combi}}{se_{combi}} \sim N(0,1)$ sous H_0
- La p_valeur
 - $2 * \phi(-|z|)$ où ϕ est la fdr de la loi normale standard




Seuil de significativité (Bonferroni)

Visualisation GWAS combinée



Chaque point représente un SNP.
Aucun point ne dépasse le seuil de significativité, avant ou après la correction pour tests multiple.

➡ Aucun SNP n'est significativement associé au cancer



Les points sont les p_valeurs observées, ils sont comparés aux p_valeurs attendues sous H_0 (droite rouge)

Ils sont pour la plupart alignés à la droite rouge

➡ SNP pas significativement associé au cancer

ANALYSE GENE-BASED : MÉTHODE VEGAS


Objectif :

- Regrouper les résultats GWAS combiné SNP par SNP pour construire une statistique globale par gène
- Tester l'association entre un gène entier (avec ses SNPs) et un phénotype (cancer) en tenant compte de la structure de dépendance entre SNPs

Méthodologie :

- Pour chaque gène, on récupère tous ses SNPs
- On construit la statistique observée :
 - Pour chaque SNP on avait le score $z_i = \frac{\beta_i}{se_i}$
 - On calcule la somme des carrés $stat_{obs} = \sum z_i^2 \sim X_k^2$ avec k nombre de SNPs si indépendants
 - Mais les SNPs sont corrélés, la loi ne suit pas une chi2 classique
 - Matrice de corrélation des SNPs du gène (LD), il faut qu'elle soit semi-définie positive
- Simulation de la loi sous H0 (pas d'association entre gène et cancer)
 - On génère des $Z \sim N(0, I)$ iid standard
 - On applique la statistique de Cholesky : $Q = CZ$ où C issu de la décomposition de Cholesky
 - $stat_{sim} = \sum Q_i^2$
- Estimation de la p_valeur VEGAS sous H0 : $p_{VEGAS} = \frac{\#\{stat_{sim} > stat_{obs}\}}{n_{sim}}$

ANALYSE GENE-BASED : MÉTHODE VEGAS



STATS_OBS ne suit **pas** une X_k^2
car SNPs **corrélés**

$$P_{VEGAS} = \frac{\#\{stat_{sim} > stat_{obs}\}}{n_{sim}}$$

SIMULATION SOUS H_0 , en
tenant compte de la corrélation
entre les SNPs

Matrice de
corrélation
des SNPs (LD)


Σ

Matrice C issus
de la
décomposition
de Cholesky
 $\Sigma = CC^T$

C

$Z \sim N(0, I)$
sous H_0

$Q = C * Z$
 $\sim N(0, \Sigma)$



MÉTHODE VEGAS

On peut générer un tableau avec nos résultats

	gene <chr>	n_snps <int>	stat_obs <dbl>	mean_sim <dbl>	p_vegas <dbl>
1	NADK	2	7.975429	2.004449	0.0275
2	PER3	12	10.319957	11.979010	0.5030
3	NMNAT1	4	1.861800	4.040104	0.7153
4	MTHFR	10	5.647801	9.935798	0.6926
5	FUCA1	3	5.006069	2.930462	0.1790
6	NROB2	3	2.904365	2.941228	0.3871

Comment interpréter ce tableau ?

- La moyenne des statistiques simulées est proche du nombre de SNPs, ce qui est attendu sous H_0 car la statistique suit environ une loi χ^2 à k ddl, et la p-valeur VEGAS correspond à la proportion des simulations dépassant la statistique observée. (espérance = k)
- p_vegas faible $\implies$ association entre gène et cancer
- p_vegas élevé $\implies$ pas d'association entre gène et cancer

Quels sont les gènes les plus impliqués dans le cancer ?

Gènes significatifs (sans correction)
 $p_vegas < 0.05$

Description: df [23 × 5] 23 gènes significatifs

	gene <chr>	n_snps <int>	stat_obs <dbl>	mean_sim <dbl>	p_vegas <dbl>
1	NADK	2	7.975429	2.004449	0.0275
12	NEGR1	93	161.556064	93.051979	0.0289
22	NMNAT2	21	47.060165	20.879842	0.0264
50	OGG1	5	14.236844	5.058563	0.0355
79	MTHFD2L	9	27.241973	9.036188	0.0179

Gènes significatifs (avec correction)
 $p_vegas < 0.05/n_sim$

Description: df [0 × 5] 0 gène significatif

0 rows

ANALYSE PATHWAY

Pathway :

Ensemble de gènes qui participent ensemble à un processus biologique particulier (ex. : réparation ADN, cycle cellulaire etc)

Objectif :

- Tester l'enrichissement en pathways biologiques des gènes
 ➡ pour un groupe de gènes connus, les gènes sont-ils **sur-représentés** dans ce groupe ?

Méthodologie :

- On se place dans les gènes significatifs (avant correction)
- Pour chaque pathway que l'on a, on construit une table de contingence
- On fait un test d'enrichissement de Fisher :
 - H_0 : " les gènes significatifs ne sont pas enrichis dans le pathway (il n'y en a pas plus que si on regardait au hasard)"
 - H_1 : " les gènes significatifs sont plus nombreux que normal dans le pathway"
 - Si $p_valeur_enrich < seuil$: le pathway est enrichi en gènes associés, pathway pourrait être biologiquement impliqué dans cancer
 - Si $p_valeur_enrich > seuil$: pas d'enrichissement

# gènes Significatifs DANS le pathway	# gènes Significatifs HORS du pathway
# gènes Non Significatifs DANS le pathway	# gènes Non Significatifs HORS du pathway

ANALYSE PATHWAY

Nos résultats

pathway	n_genes_pathway	n_signif_in_pathway	p_enrich
F_tobacco_hsa00760	23	3	0.2282264
F_pub_he2010_4	16	3	0.1009783
F_folate	4	1	0.2619771
F_obesity	47	2	0.5486499
F_xeno	63	6	0.4232323
F_oglyc_hsa00511	14	0	0.6099617
F_cell_cycle	19	1	1.0000000
F_DNA	82	5	0.8062375
F_circadian	23	1	1.0000000
F_inflammatory	25	1	1.0000000

>0.05

Comme **p_valeur_enrich >0.05** pour tout les pathways
On ne trouve aucun pathway qui serait enrichi en gènes significatifs

On peut quand même relever que certains **pathway** contiennent
plus de gènes significatifs que les autres
Ils seraient peut être plus **intéressant** biologiquement

RETOUR SUR CERTAINS GÈNES INTÉRESSANTS

Même si nous n'avons pas pu trouver de gènes significativement associés au cancer après correction pour tests multiples, on peut regarder de plus près les gènes les plus significatifs (dans un but exploratoire)

On peut regarder plus en détails leur fonction biologique **

gene	n_snps	p_vegas	pathway
PARP2	6	0.0019	F_DNA
AKR1C2	15	0.0020	F_xeno
KRAS2	10	0.0066	F_pub_he2010_4
NAT2	10	0.0110	F_xeno
MGST1	10	0.0157	F_xeno

On retrouve des gènes appartenant aux pathways les plus représentés (ce qui est logique)

Gène	Fonction principale	Lien avec le cancer	Pathway associé
PARP2	Métabolisme des stéroïdes, détoxification	Surexprimé dans plusieurs cancers, urothéliaux etc..	F_DNA
AKR1C2	Réparation de l'ADN Maintien génomique	Cible thérapeutique en oncologie	F_xeno
KRAS2	Signalisation cellulaire	Oncogène souvent muté dans les cancers (pancréas, colon, poumons...)	F_pub_he2010_4
NAT2	Métabolisme des xénobiotiques	Variants associés au risque de cancer colorectal	F_xeno
MGST1	Détoxification, protection antioxydante	?	F_xeno

** Informations trouvés sur PubMed, GeneCards, KEGG

CONCLUSION

Résumé de notre **démarche** :

- Réalisation d'une **GWAS** pour identifier les SNPs associés au cancer
- **Combinaison** des résultats sur deux échantillons
- Analyse Gene-Based (**VEGAS**) pour détecter les gènes significativement associés au cancer
- Etude d'enrichissement au niveau des **pathways**

Principaux **résultats** :

- Quelques gènes associés au cancer avant la correction pour tests multiples, aucun après
- Pas de pathway significatif détecté avant ni après correction
- Certains gènes détectés qui sont impliqués dans des fonctions biologiques associées au cancer

Limites de notre étude :

- Pas le même modèle de régression pour les 2 échantillons (3 vs 12 covariables)
- Pas de résultats robustes après correction pour tests multiples
- Taille de notre échantillon trop limitée?



Tony LI
Saïd BENAÏSSA

MERCI

Projet réalisé dans le cadre du cours Statistiques pour la
génétique et la génomique